

I. Dùng thước đo Substring matching để tự chấm điểm một hệ thống suy luận phức tạp (ReAct Agents) là chưa phù hợp.

Ví dụ: Agent phân tích “*Học phí gốc là 40 triệu (match substring), được giảm 10 triệu, vậy phải đóng 50 triệu*”. Hệ thống đánh giá dựa trên Substring Containment sẽ tự động chấm câu này là Pass (Thành công) vì nó tìm thấy chuỗi “40 triệu”, bỏ qua hoàn toàn việc Agent tính toán sai kết quả cuối cùng. Đối với một hệ thống Multi-Agent có khả năng suy luận, dùng Substring để đo lường độ chính xác (Automated Fact Pass Rate) là một phương pháp luận không phù hợp.

Giải pháp: Áp dụng các phương pháp đo lường hiện đại và chặt chẽ hơn

Bổ sung chỉ số Pass $\geq$ 50% bằng LLM-as-a-Judge (như framework RAGAS) cho độ chính xác ngữ nghĩa, kết hợp với Numeric Exact Match cho các con số tài chính, và cung cấp thêm Human Evaluation trên 100 câu test.

1. LLM-as-a-Judge (Đánh giá bằng LLM mạnh hơn)

Thay vì đếm số lượng từ khóa trùng khớp một cách máy móc, chuẩn mực hiện nay là sử dụng một LLM cấp độ cao (như GPT-4o, Claude 3.5 Sonnet) làm giám khảo (Judge).

Cách hoạt động

Cung cấp cho LLM Giám khảo (1) Câu hỏi của sinh viên, (2) Sự thật nền (Ground Truth/Reference Answer), và (3) Câu trả lời của hệ thống. Yêu cầu Giám khảo chấm điểm dựa trên một barem (rubric) khắt khe về mặt ngữ nghĩa và logic.

Ưu điểm

Giám khảo AI đủ thông minh để hiểu rằng “Học phí là 40 triệu” và “Học phí là 192 triệu nhưng bạn được giảm 40 triệu” là hai ý nghĩa hoàn toàn khác nhau, dù chúng chứa các từ khóa giống hệt nhau.

Các framework phổ biến hỗ trợ việc này là **RAGAS** hoặc **TruLens**.

2. Exact Match (Khớp tuyệt đối) cho dữ liệu tài chính

Đối với họ truy vấn tài chính, không được phép dùng Substring hay LLM-as-a-Judge để chấm chầm chước => cần sự chính xác tuyệt đối.

Cách hoạt động

Bắt buộc hệ thống phải xuất (output) con số cuối cùng dưới dạng định dạng chuẩn (ví dụ: JSON {"final_tuition": 40000000}). Sau đó, dùng code lập trình (Python) để so sánh bằng (==) con số này với Ground Truth.

Ưu điểm

Loại bỏ 100% rủi ro hệ thống bị ảo giác toán học (mathematical hallucination) nhưng vẫn qua mặt được thước đo đếm chữ như tác giả đã thú nhận ở mục 6.3.

3. Human Evaluation (Đánh giá mù từ con người)

Với tập dữ liệu (dataset) chỉ có vồn vẹn 100 câu test, việc chạy tự động bằng code là không thật sự cần thiết. 100 câu là một khối lượng công việc cực kỳ lý tưởng để con người trực tiếp đánh giá.

Cách hoạt động

Đưa 100 câu trả lời của Single Agent và 100 câu của CTU-Chat cho 2-3 chuyên gia tư vấn học vụ và nhờ họ chấm điểm (1 đến 5 sao) về tính chính xác, tính hữu ích và độ tự nhiên.

II. Áp dụng vào một tập dữ liệu quá nhỏ bé

Đánh giá độ ổn định của một kiến trúc Multi-Agent phức tạp nhưng chỉ dựa trên 100 câu test (khi chia nhỏ ra mỗi domain chỉ có khoảng 20-30 câu) là không đủ để chứng minh tính tin cậy (Reliability). Dù mình đã dùng kỹ thuật thống kê *Bootstrap resampling 10,000 lần* để làm mượt số liệu, nhưng thống kê không thể tạo ra tri thức mới nếu 100 câu hỏi ban đầu không đủ tính đại diện.

Giải pháp: Triển khai thử nghiệm thực tế

Cách làm

Triển khai CTU-Chat dưới dạng Beta cho một nhóm nhỏ (ví dụ: 100 -200 sinh viên) sử dụng trong 1 tuần. Thu thập lại 200-300 câu hỏi thực tế của sinh viên (câu sai lỗi chính tả, câu hỏi lắt léo). Dán nhãn thủ công: Chuyên viên tư vấn học vụ sẽ xem lại những câu log thật này và ghi đáp án chuẩn xác.

Lợi ích

Tập dữ liệu thu được sẽ phản ánh chính xác hành vi, văn phong (colloquialism), và các ý định (intents) phức tạp của sinh viên thật. Việc báo cáo kết quả trên một tập Real-world Test Set dù nhỏ (khoảng 200 log) cũng có giá trị khoa học và độ tin cậy cao gấp nhiều lần so với 100 câu hỏi tự tạo trong phòng thí nghiệm.