

Báo cáo Phân tích Kiến trúc Agentic RAG: Định tuyến Không gian con Ngữ nghĩa và Hệ thống Đa tác tử Bất đối xứng

1. Tóm tắt Thực thi và Đặt vấn đề

Sự tiến hóa của Trí tuệ Nhân tạo (AI) thế hệ mới đang chứng kiến một bước chuyển dịch mô hình sâu sắc từ các hệ thống Sinh văn bản Tăng cường Truy xuất (Retrieval-Augmented Generation - RAG) có cấu trúc tĩnh sang các nền tảng Tác tử tự trị (Agentic RAG). Khái niệm RAG lần đầu tiên được định hình rõ nét vào năm 2020 như một giải pháp đột phá nhằm tiêm (inject) tri thức ngoại biên vào các mô hình tham số (parametric models), giúp khắc phục triệt để hiện tượng ảo giác (hallucination) và sự lỗi thời của dữ liệu huấn luyện¹. Mặc dù phương pháp này thiết lập nên những tiêu chuẩn mới trong xử lý ngôn ngữ tự nhiên (NLP) cho các tác vụ chuyên sâu về tri thức, các hệ thống RAG truyền thống dựa vào việc truy xuất tài liệu theo không gian vector phẳng đã bộc lộ những hạn chế nghiêm trọng. Những hạn chế này đặc biệt rõ rệt trong khả năng suy luận nhiều bước (multi-hop reasoning), duy trì ngữ cảnh toàn cục, và quản lý các tác vụ phức hợp trong môi trường động². Hơn nữa, việc triển khai RAG trong các lĩnh vực đòi hỏi độ chính xác tuyệt đối, chẳng hạn như tư vấn tài chính, tính toán học phí hay quy chế đào tạo, thường vấp phải rào cản về nhiễu ngữ cảnh và sự thiếu hụt khả năng kiểm soát truy xuất một cách tất định.

Kiến trúc hệ thống Chatbot Đại học Cần Thơ được phân tích trong báo cáo này đại diện cho một bước tiến tiên phong trong việc thiết kế và triển khai Agentic RAG. Bằng cách tích hợp các công nghệ tiên tiến bao gồm LangGraph, Neo4j, Qdrant và BM25, cùng với hệ thống phân loại ý định độc đáo tại tầng giám sát (Supervisor), kiến trúc này không chỉ phản ánh các xu hướng nghiên cứu mới nhất trong giai đoạn 2024-2026 mà còn trực tiếp giải quyết những điểm nghẽn thực tiễn về hiệu năng và độ tin cậy. Báo cáo này tiến hành một cuộc mổ xẻ chuyên sâu về kiến trúc hệ thống nhằm định vị các đóng góp học thuật cốt lõi. Nội dung phân tích sẽ bắt đầu từ việc chỉ ra các khoảng trống nghiên cứu đang được giải quyết một cách trực tiếp, tiếp nối bằng việc đề xuất danh pháp khoa học chuẩn xác cho cơ chế phân luồng kết hợp giám sát, và cuối cùng là phân tích ý nghĩa học thuật sâu sắc của việc phân bổ năng lực tác tử theo mô hình bất đối xứng (Asymmetric Multi-Agent System). Thông qua phân tích này, kiến trúc hệ thống được chứng minh không chỉ là một giải pháp kỹ thuật ưu việt mà còn là một cơ sở lý luận quan trọng cho sự phát triển của hệ sinh thái phần mềm tích hợp AI trong tương lai.

2. Các Khoảng trống Nghiên cứu trong Miền Agentic RAG

Sự bùng nổ của kiến trúc RAG từ năm 2020 đến nay đã thiết lập một tiêu chuẩn mới cho các ứng dụng chuyên sâu về tri thức, diễn hình thông qua các nghiên cứu nền tảng như mô hình

Sinh văn bản Tăng cường Truy xuất (REALM) và Truy xuất Đoạn văn Dày đặc (Dense Passage Retrieval - DPR)¹. Tuy nhiên, thực tiễn triển khai công nghiệp và các khảo sát học thuật gần đây về Agentic RAG đã chỉ ra hàng loạt điểm yếu chí mạng của mô hình tuyến tính này³. Kiến trúc hệ thống đa tác tử được đề xuất đang trực tiếp can thiệp và lấp đầy bốn khoảng trống nghiên cứu trọng yếu, định hình lại cách thức các hệ thống tri thức tương tác với dữ liệu phi cấu trúc và bán cấu trúc.

2.1. Hạn chế của Truy xuất Phẳng và Nhu cầu Suy luận Mạng lưới

Các hệ thống RAG truyền thống phụ thuộc gần như hoàn toàn vào phương pháp truy xuất dựa trên vector. Mặc dù phương pháp này tỏ ra hiệu quả trong việc tìm kiếm sự tương đồng về mặt ngữ nghĩa, chúng thường xuyên thất bại khi phải đối mặt với các truy vấn đòi hỏi sự hiểu biết về mối quan hệ cấu trúc phức tạp hoặc suy luận logic nhiều bước². Các không gian vector phẳng không có khả năng nắm bắt tự nhiên các mối quan hệ logic giữa các thực thể, chẳng hạn như hệ thống các môn học tiên quyết hay sự so sánh đa chiều giữa các chương trình đào tạo khác nhau. Điều này dẫn đến việc hệ thống thường xuyên trích xuất các mảnh thông tin rời rạc, thiếu tính liên kết cấu trúc⁴.

Kiến trúc hệ thống đã giải quyết triệt để khoảng trống này thông qua mô hình Agentic GraphRAG, một lĩnh vực nghiên cứu đang nhận được sự quan tâm đặc biệt trong giới học thuật⁵. Bằng việc sử dụng Neo4j như một hệ quản trị cơ sở dữ liệu đồ thị cốt lõi và trang bị cho nhánh tác tử học vụ (Academic Agent) sáu công cụ chuyên biệt để tương tác trực tiếp, hệ thống đã chuyển đổi đồ thị từ một bảng tra cứu thụ động thành một không gian tô-pô nơi tác tử có thể tự do di chuyển và suy luận⁵. Các nghiên cứu đã quan sát thấy rằng hệ thống GraphRAG nguyên bản và hệ thống Agentic RAG độc lập đều sở hữu những chế độ thất bại mang tính chu kỳ (recurring failure modes), và việc kết hợp hai mô hình này có khả năng giảm thiểu đáng kể các rủi ro đó⁵. Việc thiết kế luồng xử lý bỏ qua hoàn toàn node truy xuất thông thường đối với các truy vấn học vụ giúp hệ thống tránh được sự sai lệch do nhiễu vector, đồng thời tận dụng tối đa tính xác định của các truy vấn đồ thị (Cypher queries) để giải quyết các cấu trúc dữ liệu đan xen phức tạp.

2.2. Vấn đề Nhiễu cảnh trong Không gian Lưu trữ Hỗn hợp

Khi một cơ sở dữ liệu vector được thiết kế để lưu trữ nhiều loại tài liệu đa dạng và khác biệt về mặt bản chất như bảng giá học phí, quy định học bổng, quy chế đào tạo, hay thông báo chung, việc sử dụng một truy vấn duy nhất để quét toàn bộ không gian dữ liệu thường mang về các kết quả có độ tương đồng ngữ nghĩa cao nhưng hoàn toàn sai lệch về mặt ý định⁶. Ví dụ, một truy vấn về chi phí đào tạo có thể kéo theo cả các văn bản về chính sách vay vốn sinh viên hoặc các chương trình hỗ trợ xã hội, làm nhiễu loạn mô hình sinh văn bản và gây ra hiện tượng pha trộn thông tin. Các nghiên cứu đánh giá hệ thống RAG cấu hình dựa trên một kho vector duy nhất (Single Vector Store) đã chỉ ra rằng hiệu suất đạt được rất thấp do giới hạn về mức độ liên quan của ngữ cảnh⁷. Cụ thể, trong các lĩnh vực đòi hỏi độ chính xác cao như trả lời câu hỏi tài chính (Financial QA), kiến trúc RAG ngây thơ (Naïve RAG) đôi khi chỉ đạt tỷ lệ chính xác xấp xỉ 41-50%⁷.

Hệ thống đề xuất đã can thiệp mạnh mẽ vào điểm nghẽn này bằng cơ chế lọc siêu dữ liệu theo tuyến (Lane System). Bằng việc định nghĩa trước các ranh giới siêu dữ liệu tương ứng với từng

ý định truy vấn cụ thể, hệ thống đảm bảo rằng bộ truy xuất chỉ quét qua một không gian con duy nhất mang tính hợp lệ tuyệt đối. Việc chuyển dịch từ một không gian mở sang không gian có điều kiện giúp nâng cao độ mạnh mẽ của ngữ cảnh và duy trì tỷ lệ thu hồi ở mức tối đa cho các truy vấn phức tạp mà không bị ảnh hưởng bởi hiện tượng phân mảnh thông tin⁶. Sự kết hợp giữa bộ lọc siêu dữ liệu cấu trúc chặt chẽ và cơ chế tìm kiếm lai (Hybrid Search) tích hợp Qdrant cho vector dày đặc, BM25 cho chỉ mục thưa thớt, và kỹ thuật dung hợp thứ hạng tương hỗ (RRF) đưa hệ thống vượt xa các đường ống RAG tiêu chuẩn về độ chính xác, tỷ lệ thu hồi và khả năng xếp hạng². Kỹ thuật tìm kiếm lai kết hợp lọc siêu dữ liệu cũng được chứng minh là cung cấp khả năng hiệu chuẩn độ tin cậy mạnh mẽ, một yếu tố then chốt để hạn chế tối đa các suy diễn sai lệch⁸.

2.3. Kiểm soát Ảo giác và Mức độ Đáng tin cậy trong Dữ liệu Rủi ro Cao

Tính chính xác của số liệu là yếu tố sống còn trong các tác vụ liên quan đến tài chính, học phí, hoặc các chính sách miễn giảm, vốn được xếp vào nhóm miền ứng dụng có rủi ro cao (high-stakes domains). Sự kết hợp giữa kiến trúc RAG và các luồng công việc tác tử tự trị tạo ra cơ hội lớn để cải thiện độ trung thực ở mức độ mệnh đề (statement-level faithfulness), nhưng mặt khác, việc cho phép một tác tử tự do lặp lại các vòng lặp suy luận với các công cụ truy xuất không bị giới hạn có thể dẫn đến việc kết nối sai các bảng biểu hoặc LLM tự kích hoạt khả năng "sáng tạo" ra các công thức tính toán phi thực tế⁴.

Thay vì sử dụng một tác tử truy xuất mở thông thường, kiến trúc phân định vô cùng rõ ràng cách thức hoạt động của nhánh tác tử tài chính. Mặc dù là một tác tử ReAct, nó được cung cấp sẵn một ngữ cảnh động đã được tinh lọc thông qua node truy xuất trước khi bắt đầu chu trình suy nghĩ. Bằng cách khóa chặt phạm vi tài liệu thông qua các tuyến cụ thể như học phí thực tế hay cơ sở miễn giảm, và cung cấp các công cụ tính toán toán học tất định, hệ thống đã cơ khí hóa quá trình tư duy của LLM. Khối lượng tri thức bên ngoài được chuyển qua các đường ống riêng biệt trước khi cung cấp cho LLM sinh văn bản, giúp kiểm soát hoàn toàn đầu ra và hỗ trợ truy xuất nguồn gốc rõ ràng⁴. Khung làm việc này phản ánh chính xác tư duy thiết kế Agentic RAG cho các lĩnh vực rủi ro cao, nơi quá trình truy xuất đa bước được kiểm soát chặt chẽ nhằm vượt qua các giới hạn của phương pháp tiếp cận RAG truyền thống⁷. Hơn nữa, việc cố định đầu vào bằng các văn bản đã xác thực cũng giúp hệ thống đáp ứng được các nguyên tắc bảo mật và toàn vẹn dữ liệu cơ bản, một điều kiện tiên quyết cho các AI có khả năng triển khai thực tế⁹.

2.4. Rào cản Chi phí Tính toán và Độ trễ trong Hệ thống Đa tác tử

Các hệ thống đa tác tử hiện hành thường thiết lập cấu hình mọi điểm nút (node) trong mạng lưới như một tác tử ReAct hoàn chỉnh. Mặc dù các mô hình như vậy có khả năng tự thích ứng cao, nhưng việc áp dụng vòng lặp suy nghĩ - hành động - quan sát (Thought-Action-Observation) cho mọi truy vấn, bất kể mức độ phức tạp, tạo ra sự gia tăng bất đối xứng trong chi phí suy luận (asymmetric reasoning overhead)¹⁰. Các vòng lặp này tiêu tốn số lượng token khổng lồ, tạo ra nhiều luồng dữ liệu trung gian dư thừa và kéo dài thời gian phản hồi của hệ thống, làm cản trở nghiêm trọng tính khả thi khi triển khai trên quy mô công nghiệp³.

Kiến trúc hệ thống sử dụng một mô hình đa tác tử bất đối xứng, thể hiện qua việc định tuyến các câu hỏi mang tính chất tổng quan vào một chuỗi xử lý tuyến tính thay vì một tác tử hoàn chỉnh. Bằng việc phân tách rõ ràng luồng xử lý này, hệ thống đã triệt tiêu chi phí suy luận lãng phí đối với các truy vấn không đòi hỏi việc gọi công cụ (tool calling). Đóng góp này trực tiếp lấp đầy khoảng trống về hiệu quả triển khai môi trường sản xuất của Agentic RAG, đồng thời thiết lập một sự cân bằng tinh tế giữa chi phí vận hành, tốc độ phản hồi và độ phức tạp của toàn bộ quy trình kiến trúc⁹.

Khoảng trống Nghiên cứu trong Agentic RAG	Hạn chế của Kiến trúc Truyền thống	Cơ chế Giải quyết trong Hệ thống Đề xuất
Giới hạn của Truy xuất Phẳng	Bỏ qua cấu trúc logic, không thể thực hiện các thao tác suy luận đa bước.	Tác tử Đồ thị Trực tiếp: Sử dụng công cụ Neo4j cho phép duyệt đồ thị linh hoạt không qua vector.
Nhiều Ngữ cảnh Đa miền	Sinh ảo giác do trộn lẫn thông tin thuộc nhiều lĩnh vực có sự tương đồng từ vựng.	Hệ thống Lọc Siêu dữ liệu: Thu hẹp không gian tìm kiếm triệt để theo ý định dự báo bởi LLM.
Độ tin cậy trong Tác vụ Định lượng	Rủi ro tính toán sai do kết hợp sai số liệu từ các bảng giá hỗn hợp.	Ngữ cảnh Tinh lọc Nạp sẵn: Kết hợp công cụ tính toán tắt định giới hạn trong luồng RAG lại.
Chi phí Suy luận Bất đối xứng	Overhead quá lớn khi mọi truy vấn đều chạy qua các vòng lặp ReAct dư thừa.	Kiến trúc Đa tác tử Bất đối xứng: Phân rã mức độ tự trị (ReAct vs. Simple Chain) theo độ khó.

3. Khái niệm hóa Đóng góp Học thuật: Danh pháp Khoa học cho "Hệ thống Lane + Supervisor Routing"

Trong kiến trúc của hệ thống, sự kết hợp giữa chức năng phân loại ý định tại node giám sát trung tâm (Supervisor Routing) và việc ánh xạ các ý định đó thành ranh giới siêu dữ liệu để thu hẹp không gian vector (Hệ thống Lane) là một thiết kế mang tính hệ thống rất cao. Để định hình thiết kế này thành một đóng góp mới (novelty) mang tầm vóc một bài báo khoa học chuẩn mực, thuật ngữ kỹ thuật đơn thuần của kỹ sư phần mềm cần được nâng cấp thành một danh pháp học thuật phản ánh cơ chế toán học và hệ thống học cơ sở của nó.

3.1. Phân tích Bản chất Toán học và Xác suất

Về mặt nền tảng toán học, một hệ thống RAG tiêu chuẩn hoạt động dựa trên nguyên lý tối đa hóa xác suất sinh ra văn bản mục tiêu y dựa trên truy vấn đầu vào x và một tập hợp các tài liệu z_i được truy xuất từ toàn bộ không gian tài liệu bao quát D . Công thức này được biểu diễn dưới dạng:

$$P(y|x) = \sum_{i=1}^k P_{\theta}(y|x, z_i) P_{\phi}(z_i|x)$$

Trong phương trình trên, $P_{\phi}(z_i|x)$ đại diện cho phân phối của bộ truy xuất trên không gian D (thường được thực hiện thông qua hàm softmax của các điểm tích vô hướng hoặc khoảng cách cosin), và $P_{\theta}(y|x, z_i)$ là xác suất có điều kiện của mô hình sinh văn bản¹. Tuy nhiên, trong một không gian dữ liệu khổng lồ và phức hợp, việc bộ truy xuất P_{ϕ} tiến hành đánh giá trên toàn bộ tập D sẽ tất yếu dẫn đến tình trạng nhiễu do sự chồng chéo ngữ nghĩa giữa các miền kiến thức. Cơ chế của hệ thống Chatbot Đại học Cần Thơ đã làm thay đổi hoàn toàn công thức kinh điển này. Thay vì thực thi tìm kiếm trực tiếp trên D , mô hình ngôn ngữ lớn tại tầng giám sát thực hiện một hàm phân loại đa lớp trước thời gian thực thi (pre-execution classification), dự đoán một tập hợp các ràng buộc siêu dữ liệu L tương ứng với các luồng (Lanes) chuyên biệt. Từ đó, quá trình truy xuất vector không còn là một bài toán tìm kiếm toàn cục mà trở thành một mô hình **Xác suất có điều kiện bị chặn (Bounded Conditional Probability)**:

$$P_{\phi}(z_i|x, L) = \begin{cases} \text{score}(x, z_i) & \text{nếu } z_i \in L \\ 0 & \text{nếu } z_i \notin L \end{cases}$$

Cách tiếp cận mang tính cấu trúc này chuyển dịch hệ hình từ mô hình truy xuất ngữ nghĩa mở sang mô hình định tuyến không gian con có điều kiện. Việc mô hình ngôn ngữ thực hiện "hai quyết định trong một lần gọi" (cấu trúc đầu ra Pydantic bao gồm cả tác tử tiếp theo và ý định tài liệu) thể hiện sự tích hợp chặt chẽ, không thể tách rời giữa logic điều hướng hành vi của tác tử và logic phân hoạch không gian tri thức.

3.2. Đề xuất Danh pháp Khoa học và Kiến trúc

Để phản ánh chính xác cấu trúc toán học và quy trình dòng chảy dữ liệu này, danh pháp khoa học đề xuất cho cơ chế là:

Intent-Conditioned Semantic Subspace Routing (ICSSR)(*Định tuyến Không gian con Ngữ nghĩa theo Điều kiện Ý định*)

Hoặc một biến thể nhấn mạnh hơn vào khía cạnh truy xuất và bản thể luận dữ

liệu:**Ontology-Driven Bounded Retrieval Orchestration (OD-BRO)**(*Điều phối Truy xuất Bị chặn Dẫn dắt bởi Bản thể luận*)

Tuy nhiên, thuật ngữ được khuyến nghị sử dụng nhất, nhằm đảm bảo tính trực quan và khả năng trích dẫn cao trong các bài báo khoa học là:

Intent-Guided Subspace Retrieval Routing (IG-SRR) kết hợp với cơ sở hạ tầng **Deterministic Retrieval Lanes (DRL)**.

Trong khuôn khổ của một báo cáo khoa học, khái niệm này cần được cấu trúc hóa thông qua hai khía cạnh mật thiết:

- **Intent-Guided Routing (Định tuyến dẫn dắt bởi Ý định):** Đây là vai trò của tầng giám sát trung tâm trong việc trừu tượng hóa các suy luận ngữ nghĩa tinh vi từ câu hỏi thô của người dùng. Tầng này không chỉ đóng vai trò phân phối công việc (xác định tác tử xử lý) mà còn đóng vai trò như một người gác cổng tri thức (xác định vùng phân hoạch tri thức nào được phép chạm tới).
- **Subspace Retrieval thông qua Deterministic Retrieval Lanes (Truy xuất Không gian con qua Tuyến Tắt định):** Là quá trình dịch mã các ý định trừu tượng thành các bộ lọc siêu dữ liệu cứng (hard constraints). Điều kiện này tạo ra các tuyến (lanes) - trên thực tế là các không gian con độc lập về mặt trực giao bên trong cơ sở dữ liệu Qdrant và BM25. Cơ chế này cô lập hoàn toàn sự rò rỉ ngữ nghĩa giữa các miền dữ liệu không liên quan, bảo vệ bộ truy xuất khỏi các văn bản tương đồng bề mặt nhưng sai lệch bản chất.

3.3. Luận giải Tính mới và Đóng góp vào Tri thức Mở

Nếu một hệ thống chỉ sử dụng chức năng lọc siêu dữ liệu (metadata filtering), nó đơn thuần chỉ đang khai thác một tính năng sẵn có của cơ sở dữ liệu vector. Tương tự, nếu chỉ sử dụng định tuyến ngữ nghĩa (semantic routing), đó cũng chỉ là một khuôn mẫu (pattern) cơ bản của các mô hình ngôn ngữ lớn. Tính mới đột phá (novelty) của kiến trúc IG-SRR nằm ở cơ chế liên kết động (coupled dynamic architecture) giữa hai yếu tố này.

Đóng góp đầu tiên là sự **Dự báo Siêu dữ liệu Động (Dynamic Metadata Anticipation)**. Theo truyền thống, các hệ thống RAG thường trích xuất thực thể có tên (NER) từ câu hỏi để làm khóa lọc siêu dữ liệu. Ngược lại, trong mô hình IG-SRR, mô hình ngôn ngữ được yêu cầu phải tiên đoán bản chất của tài liệu cần thiết để trả lời câu hỏi. Ví dụ, truy vấn "tính tiền phải đóng sau giảm 70% ngành Luật" hoàn toàn không chứa từ khóa "cơ sở" hay "chính sách". Tuy nhiên, hệ thống vẫn tự động suy diễn và kích hoạt đồng thời ba luồng kết hợp để tổng hợp bối cảnh đa chiều. Khả năng ánh xạ một-nhiều (một ý định kết nối đến nhiều luồng tài liệu liên kết) cho phép trích xuất kết hợp các loại văn bản đa dạng thành một ngữ cảnh thống nhất, khắc phục triệt để điểm mù logic của tìm kiếm vector đơn thuần².

Đóng góp thứ hai là cơ chế **Khử Nhiễu Suy luận ngay tại Nguồn (Source-Level Reasoning Denoising)**. Bằng cách khóa chặt vùng tìm kiếm thành các không gian con tắt định, bộ kết hợp thông tin (dù là kiến trúc Fusion-in-Decoder hay một ReAct Agent) được bảo vệ tối đa khỏi các phân đoạn văn bản gây hiểu lầm. Sự tồn tại của các cấu trúc phân cấp tinh vi trong Agentic RAG cho phép chuyển chiến lược tìm kiếm từ trích xuất mù quáng sang một quy trình đưa ra

quyết định thích ứng, gia tăng khả năng đánh giá lại các kết quả trung gian và củng cố độ tin cậy của toàn hệ thống².

Cuối cùng là việc **Tối ưu hóa Kỹ thuật Tìm kiếm Lai trên Tập Dữ liệu Thu hẹp**. Bằng cách áp dụng quy trình lai kết hợp tìm kiếm ngữ nghĩa theo vector (Qdrant) và tìm kiếm từ vựng thưa thớt (BM25) bên trong một luồng đã được tinh lọc chặt chẽ, hệ thống triết tiêu được cả hai yếu điểm lớn: hiện tượng BM25 thiên vị các từ khóa vô nghĩa xuất hiện dày đặc và hiện tượng mô hình vector thiên vị các câu tương đồng nhưng khác bối cảnh sử dụng. Việc dung hợp thứ hạng tương hỗ trong không gian nhỏ hơn cung cấp một cơ sở tính toán đáng tin cậy cho việc hiệu chuẩn mức độ tự tin (confidence calibration), một đặc tính được xem là cốt lõi cho sự an toàn của hệ thống AI⁸.

Tính năng RAG Truyền thống	Kiến trúc IG-SRR (Hệ thống đề xuất)	Mức độ Cải tiến Học thuật / Ý nghĩa
Định tuyến (Routing)	Dựa trên từ khóa tĩnh hoặc rules rẽ nhánh cứng.	Dựa trên dự báo Intent của LLM thông qua cấu trúc đầu ra có định dạng (Pydantic). Cho phép nắm bắt linh hoạt ý nghĩa tiềm ẩn.
Lọc Siêu dữ liệu	Lọc tĩnh, thường do người dùng cung cấp explicit parameters.	Ánh xạ một-nhiều: LLM phân loại ý định, hệ thống tự động kích hoạt tổ hợp nhiều luồng tương ứng. Cải thiện ngữ cảnh.
Không gian Tìm kiếm	Quét toàn cục (Global Vector Search) trên mọi miền dữ liệu.	Tìm kiếm trong không gian con (Subspace Search) được ủy quyền. Cải thiện triệt để tỷ lệ nhiễu và độ tập trung ngữ nghĩa.

4. Ý nghĩa Học thuật của Hệ thống Đa tác tử Bất đối xứng (Asymmetric Multi-Agent System)

Bức tranh toàn cảnh của tài liệu khoa học hiện hành và các khung kiến trúc phần mềm phổ biến (như AutoGen hay CrewAI) có xu hướng thiết kế các hệ thống đa tác tử dưới dạng đồng nhất (Homogeneous Multi-Agent Systems). Trong các kiến trúc này, mỗi thành phần nút mạng đều được xây dựng như một mô hình lập luận và hành động (ReAct) hoàn chỉnh, sở hữu khả năng tự lên kế hoạch, tự quyết định công cụ tương tác, lặp lại chu trình suy luận và tự kiến tạo phản hồi. Mặc dù tối đa hóa tính linh hoạt, cách tiếp cận này phớt lờ chi phí biên của các thao tác

nhận thức. Ngược lại, kiến trúc được đề xuất trong hệ thống phân vùng các tác tử thành các cấp độ **Bất đối xứng (Asymmetric)** một cách có chủ đích và chiến lược: tác tử học vụ sử dụng chu trình ReAct thuần túy tương tác với đồ thị; tác tử tài chính sử dụng ReAct nhưng bị giới hạn bởi ngữ cảnh nạp sẵn từ luồng truy xuất; và tác tử tổng quan chỉ đơn giản là một chuỗi xử lý tuyến tính không có vòng lặp suy luận.

Sự phân mảnh cấu trúc này tạo ra một đóng góp học thuật mang tính nền tảng trong việc thiết kế các mô hình tính toán dựa trên tác tử. Khía cạnh bất đối xứng giải quyết những giới hạn cố hữu về khả năng mở rộng, tính an toàn và chi phí vận hành mà các nhà nghiên cứu đang phải đối mặt.

4.1. Sự Phân bổ Năng lực Nhận thức Bất đối xứng và Hiệu quả Tính toán

Một trong những thách thức chưa có lời giải thỏa đáng của Trí tuệ Nhân tạo Tác tử là chi phí nhận thức (cognitive overhead) khổng lồ đi kèm với mức độ tự chủ². Một tác tử dựa trên ReAct, để hoàn thành một chu trình tư duy cơ bản, đòi hỏi ít nhất ba đến năm lượt gọi LLM tuần tự cho mỗi truy vấn phức tạp. Nếu hệ thống áp đặt cấu trúc đồng nhất này cho mọi loại truy vấn, bao gồm cả những câu hỏi vấn đáp thông thường, kiến trúc đó sẽ gánh chịu một sự gia tăng bất đối xứng trong chi phí suy luận so với giá trị thông tin thực tế mang lại¹⁰. Việc thiết kế kiến trúc bất đối xứng thể hiện sự áp dụng tinh tế của "Nguyên tắc Đặc quyền Tối thiểu" (Principle of Least Privilege) trong môi trường nhận thức máy tính.

Đối với nhánh tác tử tổng quan (General Agent), hệ thống thiết kế theo cơ chế chuỗi tuyến tính (Zero-shot Chain). Tác tử này bị tước bỏ hoàn toàn năng lực gọi công cụ và khả năng lặp lại suy luận. Thay vào đó, nó buộc phải biên dịch câu trả lời ngay lập tức từ ngữ cảnh được hệ thống truy xuất cung cấp. Cơ chế này tối ưu hóa độ trễ về mức tối thiểu, tương đương với một lần gọi LLM duy nhất, tạo ra giải pháp hoàn hảo cho các tác vụ hỏi đáp thông thường với chi phí tính toán biên siêu thấp¹⁰. Trái ngược lại, nhánh tác tử học vụ (Academic Agent) được trao quyền tự chủ cao nhất, cho phép thực hiện việc duyệt lặp lại đơn tác tử (single-agent iterative traversal) trên môi trường đồ thị tri thức đa chiều⁵. Khác với các hệ thống truy xuất vector phụ thuộc vào số lượng đoạn văn cố định, các truy vấn phức tạp liên quan đến chuỗi tiên quyết môn học hay so sánh năng lực đầu ra của nhiều ngành học yêu cầu khả năng điều hướng dữ liệu logic linh hoạt. Bằng cách không sử dụng ngữ cảnh nạp sẵn, hệ thống giải phóng tác tử này, cho phép nó tự do khám phá và suy diễn trong mạng lưới quan hệ của Neo4j.

Đứng ở vị trí trung gian, nhánh tác tử tài chính (Financial Agent) đại diện cho mô hình lập luận có nền tảng (Grounded ReAct). Tác tử này sở hữu năng lực sử dụng các công cụ tính toán phức tạp nhưng bị giới hạn nghiêm ngặt trong một không gian tri thức đã được đóng gói. Quá trình Agentic RAG tại đây thể hiện rõ sự can thiệp có chủ đích của kiến trúc sư hệ thống: toàn bộ chu trình tìm kiếm và lọc dữ liệu được thực hiện bởi các kỹ thuật lập trình tắt định trước khi ngữ cảnh được cấp phát cho LLM. Tác tử chỉ sử dụng công cụ toán học để vận dụng chính xác dữ liệu từ ngữ cảnh đó. Khung giới hạn này ngăn chặn triệt để hiện tượng tác tử bị rơi vào các vòng lặp vô hạn (infinite loops) trong quá trình tự tìm kiếm thông tin trên các cơ sở dữ liệu quy mô lớn, qua đó trực tiếp giải quyết bài toán rủi ro bảo mật vận hành và tính toàn vẹn của dữ liệu trong các hệ thống đòi hỏi độ chính xác toán học tuyệt đối⁶.

4.2. Khớp nối Mô hình Nhận thức với Bản chất Cấu trúc Dữ liệu

Ý nghĩa học thuật sâu sắc thứ hai của sự phân chia mức độ tự chủ bất đối xứng là việc hiện thực hóa nguyên lý đồng phôi (isomorphism) giữa tư duy nhân tạo và cấu trúc dữ liệu nền tảng. Hệ thống ngầm định một chân lý trong thiết kế cơ sở dữ liệu hiện đại: cấu trúc của quá trình suy luận phải mô phỏng lại cấu trúc của dữ liệu mà nó tương tác.

Sự tương quan giữa Đồ thị Tri thức và logic lập luận tuần tự là rất rõ ràng. Dữ liệu dạng đồ thị bao gồm các thực thể (nodes) và các mối quan hệ (edges) có tính liên kết chặt chẽ, hoàn toàn phù hợp với chuỗi logic nội tại của LLM, chẳng hạn như "sau khi truy vấn và tìm thấy thực thể chương trình học A, hãy tiếp tục truy vấn các cạnh liên kết của A để tìm các môn học tiên quyết B". Quá trình tự chủ gọi công cụ của tác tử học vụ chính là sự tái hiện trực tiếp hành vi duyệt đồ thị của con người⁴. Ở một thái cực khác, sự tương quan giữa dữ liệu bảng biểu định lượng và khả năng khai thác bị giới hạn ngữ cảnh cũng thể hiện tư duy thiết kế bảo thủ có chủ đích. Đối với các quy chế học phí, chính sách tài chính tinh, cấu trúc dữ liệu mang tính tuyệt đối và không đòi hỏi sự khám phá mở rộng. Rủi ro lớn nhất ở đây là việc mô hình sinh ra ảo giác khi xử lý các chuỗi số liệu (number hallucination) hoặc suy diễn sai các điều khoản chính sách. Bằng cách áp dụng hệ thống RAG lai với hệ thống lọc tuyến tính vi để trích xuất một ngữ cảnh có cấu trúc (structured context) hoàn chỉnh, sau đó chuyển giao cho tác tử tài chính xem như hằng số cứng, hệ thống đã loại trừ được phần lớn nguy cơ LLM tự nội suy ra dữ liệu giả mạo. Việc khớp nối chiến lược này một lần nữa cung cấp bằng chứng cho thấy Agentic RAG, khi được điều hướng đúng cách, mang lại sự ưu việt vượt trội về độ chính xác so với các cấu trúc RAG tuyến tính cũ².

4.3. Tối ưu hóa Năng lực Hướng miền và Cô lập Rủi ro

Các nghiên cứu sâu rộng về phương pháp tiêm tri thức đã chỉ ra rằng việc cố gắng tinh chỉnh toàn bộ mô hình ngôn ngữ lớn (fine-tuning) cho mọi tác vụ vừa gây ra gánh nặng tài chính khổng lồ vừa dẫn đến sự suy giảm năng lực nghiêm trọng đối với các tác vụ ngoài miền⁹. Sự trỗi dậy của Agentic RAG giải quyết điểm nghẽn đó bằng cách điều phối nhiều đường ống truy xuất độc lập, bao gồm tra cứu vector truyền thống, truy xuất đồ thị, và thậm chí là tương tác tìm kiếm trực tuyến⁴. Thiết kế kiến trúc của Chatbot Đại học Cần Thơ phản ánh mạnh mẽ triết lý "Chia để trị" (Divide and Conquer) trong hệ sinh thái tương tác với mô hình nền tảng.

Hệ thống không chỉ sở hữu sự bất đối xứng về bộ công cụ mà còn áp dụng kỹ thuật mời bất đối xứng (asymmetric prompting). Khả năng cung cấp một chuỗi mời lệnh tĩnh cho tác tử học vụ (chỉ khởi tạo một lần) đối lập hoàn toàn với chuỗi mời lệnh động, liên tục biến đổi (chứa toàn bộ dữ liệu truy xuất tức thời) của nhánh tài chính. Sự phân mảnh kiến trúc ở cấp độ prompt này mang lại lợi ích thực tiễn khổng lồ: việc tiến hành tối ưu hóa hoặc nâng cấp cho một lĩnh vực cụ thể (ví dụ: thay đổi nhà cung cấp mô hình LLM từ Gemini sang một mô hình khác mạnh về tính toán, hoặc tinh chỉnh luồng kỹ thuật prompt) sẽ không gây ra bất kỳ rủi ro hồi quy (regression) nào cho phần còn lại của hệ thống. Hơn nữa, việc giao phó vai trò phân loại ý định, định tuyến tác tử và xử lý sửa lỗi truy vấn (Query Rewrite) cho một điểm nút trung tâm duy nhất giúp tiết giảm đáng kể các bước gọi trung gian, tối giản độ trễ toàn trình của hệ thống từ lúc tiếp nhận tín hiệu đến khi hoàn tất luồng¹.

Tiêu chí Đánh giá Thiết kế	Kiến trúc Đa tác tử Đồng nhất (Traditional MAS)	Kiến trúc Bất đối xứng ICSSR (Hệ thống đề xuất)	Ý nghĩa Khoa học & Tối ưu hóa Cấu trúc
Phân bổ Quyền Tự chủ	Mọi điểm nút đều có khả năng lên kế hoạch, lập luận và tìm kiếm đa bước.	Phân cấp quyền tự chủ thành các tầng rõ rệt, từ hoàn toàn tự do đến thực thi cứng nhắc.	Bảo vệ nguyên tắc đặc quyền tối thiểu; giảm thiểu rủi ro vòng lặp hệ thống. Khớp nổi năng lực AI với mức rủi ro.
Bản chất Khai thác Ngữ cảnh	Phần lớn định tuyến qua Vector Database để trích xuất văn bản một cách đồng loạt.	Phụ thuộc bản chất nguồn dữ liệu: Đồ thị (khám phá tự do), Vector thừa/đặc (ranh giới cứng).	Đảm bảo tính đồng phiôi giữa hình thái tư duy của LLM và cấu trúc cơ sở dữ liệu nền tảng bên dưới.
Chi phí Tính toán (Tài nguyên)	Lãng phí token khổng lồ cho các chu trình tư duy đối với những truy vấn cơ bản.	Phân bổ tài nguyên tuyến tính theo độ phức tạp của ý định. Tối ưu Token và Latency.	Giải quyết trực tiếp độ trễ và hiện tượng gia tăng bất đối xứng trong chi phí suy luận của hệ thống phức hợp ¹⁰ .

5. Kết luận và Hướng đóng góp Nghiên cứu Tương lai

Kiến trúc Hệ thống Chatbot Đại học Cần Thơ không đơn thuần chỉ là một bản vẽ thiết kế phần mềm phục vụ ứng dụng cục bộ, mà sâu xa hơn, nó kiến tạo nên một mô hình luận (ontology) hoàn chỉnh cho thế hệ các hệ thống Agentic RAG hướng miền. Việc mổ xẻ các tầng giao tiếp đa chiều, từ lớp cơ sở dữ liệu lai (Qdrant, Neo4j, Redis) đến hệ thống điều phối tác tử (LangGraph), cung cấp minh chứng sắc bén cho sự trưởng thành của phương pháp luận thiết kế AI. Hệ thống đã thành công trong việc giải quyết ba bài toán cốt lõi của khoa học máy tính ứng dụng hiện đại:

Thứ nhất, nó thu hẹp đáng kể các giới hạn cố hữu của cấu trúc truy xuất mở thông qua mô hình đồ thị hóa linh hoạt, cho phép phá vỡ các giới hạn của không gian vector để thực hiện suy luận đa bước. Việc phối hợp giữa GraphRAG và Hybrid Vector/Sparse Search giải phóng năng lực tổng hợp thông tin mà không bị hạn chế bởi độ dài hay ranh giới ngữ nghĩa tĩnh².

Thứ hai, việc định hình và phát triển cơ sở lý thuyết **Intent-Guided Subspace Retrieval Routing (IG-SRR)** cung cấp một tiêu chuẩn tham chiếu hoàn toàn mới cho việc lọc siêu dữ liệu theo hướng sự kiện và ý định. Nó khẳng định rằng sự kiểm soát chặt chẽ đối với các không gian truy xuất là điều kiện tiên quyết mang tính bắt buộc nếu muốn ứng dụng AI tạo sinh vào

các lĩnh vực đòi hỏi tính xác định tuyệt đối và lòng tin của người dùng cuối⁶.

Thứ ba, sự phá vỡ cấu trúc đồng nhất để tiến tới hệ thống đa tác tử bất đối xứng (Asymmetric Multi-Agent Orchestration) là một tư duy đột phá. Sự chuyển dịch từ mô hình "Tác tử tối đa" sang cơ chế "Định tuyến Năng lực Nhận thức Tối ưu" phản ánh trình độ thiết kế cấp cao, giải quyết trúng tâm điểm những ưu tiên nghiên cứu hàng đầu về tính khả thi kinh tế, khả năng mở rộng, và bảo mật hoạt động của AI².

Dưới góc độ đóng góp học thuật, nền tảng kiến trúc này mở ra một lộ trình hứa hẹn cho các nghiên cứu định lượng trong tương lai. Để hoàn thiện và xuất bản nghiên cứu này dưới dạng một bài báo khoa học chuẩn mực, các nghiên cứu kế tiếp nên tập trung vào việc thiết lập các bộ kiểm thử tương tự định dạng MS MARCO hoặc FinanceBench⁷. Mục tiêu là định lượng hóa mức độ suy giảm tỷ lệ ảo giác (hallucination rate), đo lường độ trung thực (faithfulness), tính liên quan (relevancy), và hiệu quả tiết giảm chi phí suy luận (token overhead) của kiến trúc IG-SRR và mô hình tác tử bất đối xứng khi được đặt lên bàn cân với các nền tảng kiến trúc cơ sở hiện có. Sự thành công của các đo lường này sẽ củng cố vững chắc cho hệ hình kiến trúc lai, tạo tiền đề để triển khai các hệ thống hỗ trợ giáo dục thông minh ở quy mô toàn cầu.

Nguồn trích dẫn

1. A Systematic Review of Key Retrieval-Augmented Generation (RAG, <https://arxiv.org/html/2507.18910v1>)
2. Agentic Retrieval-Augmented Generation: A Survey on Agentic RAG, https://www.researchgate.net/publication/388080924_Agentic_Retrieval-Augmented_Generation_A_Survey_on_Agentic_RAG
3. A Systematic Literature Review of Agentic AI across the Software, <https://arxiv.org/html/2605.15245v2>
4. Evaluating Faithfulness in Agentic RAG Systems for e-Governance, <https://www.mdpi.com/2504-2289/9/12/309>
5. (PDF) A Survey of Agentic GraphRAG: From Retrieval-Augmented, https://www.researchgate.net/publication/404635891_A_Survey_of_Agentic_GraphRAG_From_Retrieval-Augmented_Generation_to_Graph-Native_Agents
6. Augmenting Large Language Models with External Data Sources, <https://www.preprints.org/manuscript/202604.0717>
7. Agentic retrieval-augmented generation for financial QA, <https://digital-library.theiet.org/doi/pdf/10.1049/icp.2025.1296?download=true>
8. Autonomous Edge-Deployed AI Agents for Electric Vehicle Charging, <https://arxiv.org/pdf/2603.08736>
9. Retrieval-Augmented Generation for Departmental T&E, <https://itea.org/journals/volume-47-2/retrieval-augmented-generation-t-and-e/>
10. An Alternative Trajectory for Generative AI - arXiv, <https://arxiv.org/html/2603.14147v1>
11. arXiv:2505.03556v1 [cs.IT] 6 May 2025, <https://arxiv.org/pdf/2505.03556>
12. Agentic Recommender Systems: A Systematic Literature Review, <https://www.computer.org/csdl/journal/ts/2026/04/11363682/2dB08bNroQM>
13. Towards Secure Systems of Interacting AI Agents - arXiv,

<https://arxiv.org/html/2505.02077v2>